

Pipeline Data Academy

Miklós Koren



Introduction

My first program



My first useful program

2.

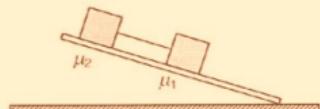
Termoszban lévő 16°C hőmérsékletű vízbe 100°C -ra melegített fémdarabot helyezünk. $36,5^{\circ}\text{C}$ közös hőmérséklet alakul ki.

Mekkora lesz a közös hőmérséklet, ha még további két, az elsővel megegyező tömegű és hőmérsékletű fémdarabot helyezünk a termoszba?

(Kopcsa József)

3.

Vízszintes helyzetű deszkán lévő, két $m = 2\text{ kg}$ tömegű testet elhanyagolható tömegű feszес fonál köt össze. A testek és a deszka közötti tapadási súrlódási együttható különböző, $\mu_1 = 0,2$ és $\mu_2 = 0,5$. A deszka egyik végét lassan emelni kezdjük. Határozzuk meg a fonálerőt e testek közös megcsúszásának határhelyzetében, a megcsúszást megelőző pillanatban!



(Kotek László)

4.

Egy szánkó össztömege 40 kg , a csúszási súrlódási tényezője a hóban $0,08$. A szánkót vízszintes talajon, álló helyzetből indulva 4 másodperc alatt egy állandó nagyságú, vízszintes irányú erővel

My first investment in data science



My three hats

- 1 Research
- 2 Teaching
- 3 Reproducibility

Research

Where: CEU MicroData, KRTK

What: firm and worker behavior in the face of globalization and technical change. Mostly observational data.

Research is fun



Especially when combined with play



Teaching

Where: CEU, European Economic Association, Carpentries, Cod-edThinking

Reproducibility

Where: Data Editor at Review of Economic Studies (#5 journal in economics)

What: Ensure data and code produce results published. Educate authors about best practices.

Academic Research

Features of academic research

- 1** Always new questions, always new data
- 2** Often new methods (!)
- 3** Batch processing of “historical” data
- 4** Diverse and changing team
- 5** Full transparency (!)

My Tools

The pragmatic programmer

The Pragmatic Programmer



from journeyman
to master

Andrew Hunt
David Thomas

Generic tools and technologies

- 1 Plain text: .csv, .md, .yaml, .tex
- 2 Command line: fish, stdin, stdout, csvkit
- 3 Version control: git, GitHub, Sublime Merge
- 4 Dependency management: Make, bead

Specific tools and technologies

- 1 Data wrangling: Python (not pandas, not .ipynb), Stata
- 2 Statistics: Stata (no R jokes please)
- 3 Simulation: Julia

Recent Projects

Recent projects

- Business Disruptions from Social Distancing
- Expatriate Managers in International Trade
- Political Favoritism in Public Procurement
- CEU-MTA Business Relations Survey

Live Demo

Home bias in public procurement

- 1 Get data from Tenders Electronic Daily on EU procurement
- 2 Check how many tenders are won by firms in the same country as the buyer
- 3 Keep all steps reproducible. Tools used:
 - Make
 - git
 - csvkit
 - SQL

Data sources

- Tenders Electronic Daily 2009
- Country codes

Bead

- Setup instructions